Indeksy, optymalizator Lab 4

Imię i nazwisko: Dariusz Piwowarski, Wojciech Przybytek

Celem ćwiczenia jest zapoznanie się z planami wykonania zapytań (execution plans), oraz z budową i możliwością wykorzystaniem indeksów.

Swoje odpowiedzi wpisuj w miejsca oznaczone jako:

Wyniki:

```
-- ···
```

Ważne/wymagane są komentarze.

Zamieść kod rozwiązania oraz zrzuty ekranu pokazujące wyniki, (dołącz kod rozwiązania w formie tekstowej/źródłowej)

Zwróć uwagę na formatowanie kodu

Oprogramowanie - co jest potrzebne?

Do wykonania ćwiczenia potrzebne jest następujące oprogramowanie

- MS SQL Server.
- SSMS SQL Server Management Studio
- przykładowa baza danych AdventureWorks2017.

Oprogramowanie dostępne jest na przygotowanej maszynie wirtualnej

Przygotowanie

Uruchom Microsoft SQL Managment Studio.

Stwórz swoją bazę danych o nazwie XYZ.

```
create database xyz
go
use xyz
go
```

Wykonaj poniższy skrypt, aby przygotować dane:

```
select * into [salesorderheader]
from [adventureworks2017].sales.[salesorderheader]
go
select * into [salesorderdetail]
from [adventureworks2017].sales.[salesorderdetail]
go
```

Dokumentacja/Literatura

Celem tej części ćwiczenia jest zapoznanie się z planami wykonania zapytań (execution plans) oraz narzędziem do automatycznego generowania indeksów.

Przydatne materiały/dokumentacja. Proszę zapoznać się z dokumentacją:

- https://docs.microsoft.com/en-us/sql/tools/dta/tutorial-database-engine-tuning-advisor
- https://docs.microsoft.com/en-us/sql/relational-databases/performance/start-and-use-the-database-engine-tuning-advisor
- https://www.simple-talk.com/sql/performance/index-selection-and-the-query-optimizer

lkonki używane w graficznej prezentacji planu zapytania opisane są tutaj:


• https://docs.microsoft.com/en-us/sql/relational-databases/showplan-logical-and-physical-operators-reference

Zadanie 1 - Obserwacja

Wpisz do MSSQL Managment Studio (na razie nie wykonuj tych zapytań):

```
– zapytanie 1
from salesorderheader sh
inner join salesorderdetail sd on sh.salesorderid = sd.salesorderid
where orderdate = '2008-06-01 00:00:00.000'
  zapytanie 2
select orderdate, productid, sum(orderqty) as orderqty,
       sum(unitpricediscount) as unitpricediscount, sum(linetotal)
from salesorderheader sh
inner join salesorderdetail sd on sh.salesorderid = sd.salesorderid
group by orderdate, productid
having sum(orderqty) >= 100
go
 – zapytanie 3
select salesordernumber, purchaseordernumber, duedate, shipdate
from salesorderheader sh
inner join salesorderdetail sd on sh.salesorderid = sd.salesorderid
where orderdate in ('2008-06-01','2008-06-02', '2008-06-03', '2008-06-04', '2008-06-05')
 – zapytanie 4
select sh.salesorderid, salesordernumber, purchaseordernumber, duedate, shipdate
from salesorderheader sh
inner join salesorderdetail sd on sh.salesorderid = sd.salesorderid
where carriertrackingnumber in ('ef67-4713-bd', '6c08-4c4c-b8')
order by sh.salesorderid
go
```


Włącz dwie opcje: Include Actual Execution Plan oraz Include Live Query Statistics:




Teraz wykonaj poszczególne zapytania (najlepiej każde analizuj oddzielnie). Co można o nich powiedzieć? Co sprawdzają? Jak można je zoptymalizować? (Hint: aby wykonać tylko fragment kodu SQL znajdującego się w edytorze, zaznacz go i naciśnij F5)

Wyniki:


1. Dla podanej daty nie istnieją żadne rekordy i MSSQL jest w stanie zopytmalizować to zapytanie, nie wykonując joina. Jeżeli jednak wybierzemy datę, dla której istnieją rekordy, to MSSQL wykona 2 full scany na obu tabelach. Można to zoptymalizować dodając index do tabeli na kolumnie orderdate żeby szybciej wybrać tylko wiersze z datą która nas interesuje oraz indeks na salesorderid w tabeli salesorderdetail żeby przyspieszyć joina.




Analiza zapytania z datą, dla której istnieją rekordy:



2. Najpierw równolegle wykonywane są Table Scan na tabelach, następnie robiony jest hash match tworzy hash mapę z salesorderid i dopasowuje rekordy z tabel do siebie czyli robi joina. Potem znowy przy pomocy hash match—a tworzona jest hash mapa gdzie kluczami są kolumny po których robimy groupby czyli orderdate, productid i potem dopasowywane są rokordy z zjoinowanej tabeli po kluczu i sumowane są tam wartości orderqty, unitpricediscount, i linetotal. Sensowne jest dodanie indeksu na salesorderid żeby przyspieszyć joina, natomiast wydaje nam się że z kolei groupby nie będzie działał szybciej nawet jeśli dodamy indeksy na orderdate, productid, bo i tak musimy przejść przez całą zjoinowaną tabelę żeby te dane zgrupować.




3. Tak samo jak w przypadku 1 (po zmianie daty na istniejące w tabeli) wykonywane są 2 full scany na tabelach salesorderheader i salesorderdetail a następnie robiony jest hash match, który tworzy hash mapę pomiędzy gdzie kluczami są salesorderid z tabeli salesorderheader które spełniają where-a, a następnie jest robione przejście po tabeli salesorderdetail i sprawdzane jest czy jego salesorderid jest w hash mapie i jeśli tak to robiony jest join. Indeksy można dodać tak samo jak 1.




4. Podobnie jak w 1 i 3 mamy 2 full scany gdzie jeden wyciąga wszystkie wiersze z salesorderheader, a drugi tylko te z salesorderdetail które spełniają where-a. Potem tabele są joinowane hash matchem tylko tym razem dopasowywane będą wiersze z salesorderheader, bo jest ich więcej (z salesorderdetail wyciągamy tylko 68 wiersze które spełniają where-a) Na końcu robione jest sortowanie po salesorderid.

Jeśli chodzi o optymalizację tego zapytania to w pierwszej kolejności sensowne jest dodanie indeksu na carriertrackingnumber, który przyspieszy where-a, potem aby przyspierszyć joina potrzebny jest indeks na salesorderid w tabeli salesorderheader (mógłby być to nawet klastrowany indeks bo salesorderid wygląda jak dobry kandydat na klucz główny w tej tabeli). Sortowanie można zrobić na końcu na tych kilkudziesięciu wierszach zjoinowanej tabeli i wtedy akurat indeks raczej nic nie przyspieszy.



Zadanie 2 - Optymalizacja

Zaznacz wszystkie zapytania, i uruchom je w **Database Engine Tuning Advisor**:



Sprawdź zakładkę **Tuning Options**, co tam można skonfigurować?


Wyniki:

Można w pierwszej kolejności wybrać PDS (Physical Design Structures) które mogą zostać użyte do tuningu. Do wyboru są między innymi indexes, indexed views, indexes and indexed views, nonclustered indexes itd. czyli w skrócie wybieramy tutaj formę w jakiej fizycznie będą zapisane nasze usprawnienia. Możemy też wybrać czy chcemy wykonać partycjonowanie. Na koniec możemy wybrać co się ma stać z istniejącymi PDS, czyli na przykład Keep all existing PDS lub Keep indexes only itd.

	192.168.64.1 - sa 4/15/2024 7:52:27 PM		
	General Tuning Options		
		■▼ 8:52 PM ♣	
	Physical Design Structures (PDS) to use in database Indexes and indexed views	O bedeved visus	☐ Include filtered indexes
ı	Indexes and indexed views	O Indexed views	Include filtered indexes
	○ Indexes	Nonclustered indexes	Recommend columnstore indexes
	Evaluate utilization of existing PDS only		
	Partitioning strategy to employ		
	No partitioning	O Full partitioning	
	Aligned partitioning		
	Physical Design Structures (PDS) to keep in database		
	O Do not keep any existing PDS	Keep indexes only	
	Keep all existing PDS	Keep clustered indexes only	
	Keep aligned partitioning		


Użyj **Start Analysis**:

2024-04-15 lab4-index-opt-1.md



Zaobserwuj wyniki w Recommendations.


Przejdź do zakładki **Reports**. Sprawdź poszczególne raporty. Główną uwagę zwróć na koszty i ich poprawę:




Zapisz poszczególne rekomendacje:

Uruchom zapisany skrypt w Management Studio.

Opisz, dlaczego dane indeksy zostały zaproponowane do zapytań:





Wyniki:

Wybraliśmy opcję indexes, bo domyślna opcja indexes and indexed views tworzy widoki, które na przykład w przypadku 2 zapytania z groupby dosłownie stworzyło widok już z joinem i groupby, więc wtedy wystarczyłoby tylko wybrać z niego wherem po warunku dane wiersze, ciekawsze wydają się same indeksy które mogą być bardziej uniwersalne do

```
różnych zapytań.

Zostało zaproponowane 6 indeksów nonclustered:
Dla tabel salesorderheader:
1. kolumny kluczowe: [OrderDate] ASC, [SalesOrderID] ASC; kolumny dołączone: pozostałe kolumny tabeli
2. kolumny kluczowe: [SalesOrderID] ASC; kolumny dołączone: [DueDate], [ShipDate], [SalesOrderNumber], [PurchaseOrderNumber]
3. kolumny kluczowe: [OrderDate] ASC; kolumny dołączone: [SalesOrderID]
Dla tabeli salesorderdetails:
4. kolumny kluczowe: [SalesOrderID] ASC; kolumny dołączone: pozostałe kolumny tabeli
5. kolumny kluczowe: [SalesOrderID] ASC, [ProductID] ASC; kolumny dołączone: [OrderQty], [UnitPriceDiscount], [LineTotal]
6. kolumny kluczowe: [CarrierTrackingNumber] ASC, [SalesOrderID] ASC

Indeksy 1, 4 optymalizują zapytania 1 i 3.
Indeksy 3, 5 optymalizują zapytania 2.
Indeksy 2, 6 optymalizują zapytanie 4.
Dokładna analiza tego w jaki sposób je optymalizują znajduje się przy porównaniu Execution Planów poniżej.
```

```
USE [XYZ]

| CREATE NONCLUSTERED INDEX [_dta_index_salesorderdetail_6_1221579390_K1_2_3_4_5_6_7_8_9_10_11] ON [dbo].[salesorderdetail]

| SalesOrderID] ASC | INCLUDE([SalesOrderDetailID],[CarrierTrackingNumber],[OrderQty],[ProductID],[SpecialOfferID],[UnitPrice],[UnitPriceDiscount],[LineTotal],[rowguid],[ModifiedDate]) WITH (SORT_IN_80 | CREATE NONCLUSTERED INDEX [_dta_index_salesorderdetail_6_1221579390_K1_K5_4_8_9] ON [dbo].[salesorderdetail] | [SalesOrderID] ASC | [ProductID] ASC | [SalesOrderID] ASC |
```


Sprawdź jak zmieniły się Execution Plany. Opisz zmiany:

Wyniki:

Indeksy numerujemy jak w powyższej liście indeksów

1. Pierwsze zapytanie dzięki indeksom zamiast robić 2 full scany wykorzystuje indeks numer 1 do wyciągnięcia z salesorderheader rekordów spełniających warunek z datą, a następnie indeks numer 4 do wyciągnięcia z salesorderdetails rekordów z pasującym SalesOrderID.

Wykorzystanie tych indeksów powoduje też że zmieniony został sposób wykonywania inner joina z hash match na nested loops, który z wykorzystaniem indeksów jest szybszy (prawdopodobnie z powodu niewielkiej liczby wierszy do której trzeba dopasować wiersz z drugiej tabeli).




2. Zamiast 2 full scanów wykonywane są 2 full index scany, pierwszy dla tabeli salesorderheader wykorzystuje indeks numer 3 a drugi


dla tabeli salesorderdetails używa indeksu numer 5. Indeks 3 wyciąga SalesOrderID posortowane po OrderDate, natomiast indeks 5 sortując po

SalesOrderID i ProductID wyciąga dane potrzebne do policzenia sum orderqty, unitpricediscount i linetotal, dzięki temu po joinie tak


pobrane dane są już posortowane po OrderDate i ProductID co pozwala na szybsze policzenie sum do groupby.



3. Plan wykonania taki sam jak w 1. oraz wykorzystywane są te same indeksy.



4. Wykonywany jest index seek który wyciąga z tabeli salesorderdetails dane o odpowienim carriertrackingnumber przy pomocy indeksu numer 6, dane są od razu sortowane po SalesOrderID jeszcze przed joinem. Dla wyciągniętych SalesOrderID robiony jest drugi index seek na tabeli salesorderheader używający indeksu numer 2, który wyciąga pozostałe potrzebne dane. Na koniec robiony jest join i dane po joinie są już posortowane.



Zadanie 3 - Kontrola "zdrowia" indeksu

Dokumentacja/Literatura

Celem kolejnego zadania jest zapoznanie się z możliwością administracji i kontroli indeksów.

Na temat wewnętrznej struktury indeksów można przeczytać tutaj:

- https://technet.microsoft.com/en-us/library/2007.03.sqlindex.aspx
- https://docs.microsoft.com/en-us/sql/relational-databases/system-dynamic-management-views/sys-dm-db-index-physical-stats-transact-sql
- https://docs.microsoft.com/en-us/sql/relational-databases/system-dynamic-management-views/sys-dm-db-index-physical-stats-transact-sql
- https://docs.microsoft.com/en-us/sql/relational-databases/system-catalog-views/sys-indexes-transact-sql

Sprawdź jakie informacje można wyczytać ze statystyk indeksu:

```
select *
from sys.dm_db_index_physical_stats (db_id('adventureworks2017')
,object_id('humanresources.employee')
,null -- null to view all indexes; otherwise, input index number
,null -- null to view all partitions of an index
,'detailed') -- we want all information
```

Jakie są według Ciebie najważniejsze pola?

```
Wyniki:
```


```
Naszym zdaniem najważniejsze pola to:
- database_id, object_id, index_id (pola pozwalające na identyfikację rekordu)
- index_type_desc (typ indeksu)
- avg_fragmentation_in_percent (średni procent fragmentacji, może sugerować kiedy należy przebudować indeks)
- avg_page_space_used_in_percent (ile procent każdej strony indeksu jest zajęte, dla odczytu lepszy duży procent,
    dla zapisywania lepszy mały procent)
- record_count (ilość rekordów w indeksie, określa jak duży jest indeks)
- ghost_record_count (ilość zbędnych rekordów, które zostaną usunięte przez system)
```

Sprawdź, które indeksy w bazie danych wymagają reorganizacji:

```
use adventureworks2017


select object_name([object_id]) as 'table name',
  index_id as 'index id'
from sys.dm_db_index_physical_stats (db_id('adventureworks2017')
  ,null -- null to view all tables
  ,null -- null to view all indexes; otherwise, input index number
  ,null -- null to view all partitions of an index
  ,'detailed') --we want all information
  where ((avg_fragmentation_in_percent > 10
  and avg_fragmentation_in_percent < 75
  and avg_page_space_used_in_percent < 75)
  and avg_page_space_used_in_percent > 60)) --page density
  and page_count > 8 -- we do not want indexes less than 1 extent in size
  and index_id not in (0) --only clustered and nonclustered indexes
```

Wyniki: zrzut ekranu/komentarz:



Zapytanie zwróciło indeksy jako nazwe tabeli i numer indeksu, aby odczytać nazwy indeksów wykonaliśmy dodatkowe zapytanie:

```
select sys.objects.name, sys.indexes.index_id, sys.indexes.name
from sys.indexes
inner join sys.objects on sys.indexes.object_id = sys.objects.object_id
where sys.objects.name in ('JobCandidate', 'ProductModel', 'BillOfMaterials', 'WorkOrder', 'WorkOrderRouting')
```



Ostatecznie odczytaliśmy nazwy indeksów wymagających reorganizacji:

- PK_JobCandidate_JobCandidateID
- PK_ProductModel_ProductModelID
- PK_BillOfMaterials_BillOfMaterialsID
- IX_WorkOrder_ProductID
- IX_WorkOrderRouting_ProductID


Sprawdź, które indeksy w bazie danych wymagają przebudowy:

```
use adventureworks2017

select object_name([object_id]) as 'table name',
index_id as 'index id'
from sys.dm_db_index_physical_stats (db_id('adventureworks2017')
,null -- null to view all tables
,null -- null to view all indexes; otherwise, input index number
,null -- null to view all partitions of an index
,'detailed') --we want all information
where ((avg_fragmentation_in_percent > 15) -- logical fragmentation
or (avg_page_space_used_in_percent < 60)) --page density</pre>
```

and page_count > 8 — we do not want indexes less than 1 extent in size and index_id not in (0) —only clustered and nonclustered indexes

Wyniki: zrzut ekranu/komentarz:



- W analogiczny sposób odczytaliśmy nazwy indeksów wymagających przebudowy:
- XMLPATH_Person_Demographics
- XMLPROPERTY_Person_Demographics
- XMLVALUE_Person_Demographics

Czym się różni przebudowa indeksu od reorganizacji?


(Podpowiedź: http://blog.plik.pl/2014/12/defragmentacja-indeksow-ms-sql.html)

Wyniki:

Reorganizacja defragmentuje poszczególne strony indeksu, nie usuwa jednak fragmentacji pomiędzy stronami i nie zmienia ich struktury. Jest to proces nie zajmujący dużo dodatkowej pamięci. Przebudowa tworzy nowy indeks, a następnie usuwa stary. W jej trakcie eliminowana jest cała fragmentacja nie tylko ze stron, ale również między stronami. Jest to jednak proces bardziej kosztowny i wymagający więcej dodatkowej pamięci niż reorganizacja.

Sprawdź co przechowuje tabela sys.dm_db_index_usage_stats:

Wyniki:



Przechowuje informacje na temat liczby użyć i daty ostatniego użycia operacji seek, scan, lookup i update na poszczególnych indeksach przez użytkownika i system.

Napraw wykryte błędy z indeksami ze wcześniejszych zapytań. Możesz użyć do tego przykładowego skryptu:

```
use adventureworks2017
 -table to hold results
declare @tablevar table(lngid int identity(1,1), objectid int,
index_id int)
insert into @tablevar (objectid, index_id)
select [object_id],index_id
from sys.dm_db_index_physical_stats (db_id('adventureworks2017')
,null -- null to view all tables
,null -- null to view all indexes; otherwise, input index number
,null -- null to view all partitions of an index
,'detailed') --we want all information
where ((avg_fragmentation_in_percent > 15) -- logical fragmentation
or (avg_page_space_used_in_percent < 60)) --page density
and page\_count > 8 — we do not want indexes less than 1 extent in size
and index\_id not in (0) —only clustered and nonclustered indexes
select 'alter index ' + ind.[name] + ' on ' + sc.[name] + '.'
+ object_name(objectid) + ' rebuild'
from @tablevar tv
inner join sys.indexes ind
on tv.objectid = ind.[object_id]
and tv.index_id = ind.index_id
inner join sys.objects ob
on tv.objectid = ob.[object_id]
inner join sys.schemas sc
on sc.schema_id = ob.schema_id
```

Napisz przygotowane komendy SQL do naprawy indeksów:

Wyniki:

```
alter index XMLPATH_Person_Demographics on Person.Person rebuild alter index XMLPROPERTY_Person_Demographics on Person.Person rebuild alter index XMLVALUE_Person_Demographics on Person.Person rebuild alter index PK_JobCandidate_JobCandidate_ID on HumanResources.JobCandidate reorganize alter index PK_ProductModel_ProductModelID on Production.ProductModel reorganize alter index PK_BillOfMaterials_BillOfMaterials_ID on Production.BillOfMaterials reorganize alter index IX_WorkOrder_ProductID on Production.WorkOrder reorganize alter index IX_WorkOrder_ProductID on Production.WorkOrderRouting reorganize
```

Zadanie 4 - Budowa strony indeksu

Dokumentacja

Celem kolejnego zadania jest zapoznanie się z fizyczną budową strony indeksu

- https://www.mssqltips.com/sqlservertip/1578/using-dbcc-page-to-examine-sql-server-table-and-index-data/
- https://www.mssqltips.com/sqlservertip/2082/understanding-and-examining-the-uniquifier-in-sql-server/
- http://www.sqlskills.com/blogs/paul/inside-the-storage-engine-using-dbcc-page-and-dbcc-ind-to-find-out-if-page-splits-ever-roll-back/

Wypisz wszystkie strony które są zaalokowane dla indeksu w tabeli. Użyj do tego komendy np.:

```
dbcc ind ('adventureworks2017', 'person.address', 1)
-- '1' oznacza nr indeksu
```

Zapisz sobie kilka różnych typów stron, dla różnych indeksów:

Wyniki:

```
11712 person.address, 1, PageType 1
17856 production.workorder, 3, PageType 2
1168 person.person, 1, PageType 3
1135 person.emailaddress, 1, PageType 10
```

Włącz flagę 3604 zanim zaczniesz przeglądać strony:

```
dbcc traceon (3604);
```

Sprawdź poszczególne strony komendą DBCC PAGE. np.:

```
dbcc page('adventureworks2017', 1, 13720, 3);
```

Zapisz obserwacje ze stron. Co ciekawego udało się zaobserwować?

Wyniki:

Strona zawiera następujące sekcje: numer strony, buffer, header, allocation status i dane. Dane podzielone są na sloty i kolumny, przy czym każda kolumna ma podaną długość. Istnieją również puste sloty, które nie mają kolumn.

Nieco inna jest ostatnia ze sprawdzanych stron o typie 10, czyli IAM (Index Allocation Map). Opisuje ona jakie strony są zaalokowane w jednostce alokacji przypisanej do danej strony IAM.

Punktacja:

zadanie	pkt
1	3
2	3
3	3
4	1
razem	10